

BAB IV

KLASIFIKASI

A. Capaian Pembelajaran

Pada pertemuan kali ini diharapkan mahasiswa/i dapat menganalisa tentang:

1. Konsep Dasar Klasifikasi
2. Decision Tree Dan Model Overfitting

B. Materi

1. Konsep Dasar Klasifikasi

Klasifikasi adalah teknik yang digunakan untuk membuat diagram yang mewakili klasifikasi data yang dimulai dengan variabel prekursor (Clarisse, 2018).

Model klasifikasi sering digunakan untuk mengelompokkan data berdasarkan label yang ditentukan dari sampel data yang akan diklasifikasikan. Dalam data mining, klasifikasi termasuk dalam metode supervised learning, yaitu metode yang digunakan untuk menemukan hubungan antara atribut input dan atribut target. Klasifikasi dilakukan dengan tujuan untuk

meningkatkan reliabilitas hasil dan mendapatkan hasil terbaik dari data.

Pengoperasian metode klasifikasi adalah proses dua langkah. Tahap pertama dari proses klasifikasi dikenal juga dengan pemetaan atau pembelajaran suatu fungsi, suatu fungsi pemetaan dapat memprediksi label kelas Y dalam himpunan X . Pemetaan ini direpresentasikan sebagai aturan klasifikasi, pohon keputusan atau rumus matematika. Aturan atau pohon ini dapat digunakan untuk mengklasifikasikan kumpulan data baru (Han, 2006). Langkah kedua adalah membangun classifier yang akan digunakan untuk mengklasifikasikan data. Pertama, keakuratan prediksi kategoris diperkirakan. Jika Anda menggunakan set pelatihan untuk mengukur akurasi pengklasifikasi, estimasi akan optimis karena data yang digunakan untuk melatih pengklasifikasi juga merupakan set pelatihan. Oleh karena itu, digunakan test set yang merupakan kumpulan tupel dan label kelasnya yang dipilih secara acak dari dataset. Test set independen dari training set karena test set tidak digunakan untuk membangun classifier (Han, 2006).

Metode klasifikasi termasuk dalam "supervised learning" karena label kelas dari setiap himpunan telah disediakan. Tidak seperti "pembelajaran tanpa pengawasan" di mana label kelas dari setiap tupel tidak diketahui. Metode yang menggunakan unsupervised

learning adalah clustering (Han, 2006). Ada beberapa algoritma pembelajaran mesin yang menggunakan metode klasifikasi ini, seperti K Nearest Neighbors, Decision Trees (C4.5) dan Naïve Bayes, Neural Networks.

2. Decision Tree Dan Model Overfitting

a. Algoritma Decision Tree

Decision Tree adalah cara mengklasifikasi yang menggunakan struktur pohon yang setiap simpul mewakili atribut dan setiap cabang mewakili nilai atribut dan setiap daun mewakili nilai kelas. *Node's* tertinggi dalam *decision tree* disebut root (Gorunescu, 2011).

Algoritma C4.5 merupakan algoritma klasifikasi data dengan teknik pohon keputusan hemat biaya. Misalnya, dapat menangani data numerik (kontinu) dan diskrit, dapat menangani nilai atribut yang hilang, menghasilkan aturan yang mudah dipahami, dan paling cepat di antara yang lainnya (Luthfi. 2009).

Langkah-langkah dari algoritma C4.5 adalah :

Pilihan atribut class sebagai akar.

Membuat cabang atribut untuk setiap nilai.

Berbagi kasus dalam cabang atribut.

Mengulangi proses untuk setiap cabang atribut sampai semua kasus pada cabang atribut memiliki kelas yang sama.

Latihan Algoritma C45 Menggunakan Rapid miner

- Lakukan eksperimen mengikuti buku Matthew North, Data Mining for the Masses 2nd Edition, 2016, Chapter 10 (Decision Tree), p 195-217
- Datasets:
 - eReaderAdoption-Training.csv
 - eReaderAdoption-Scoring.csv
- Analisis peran metode pruning pada decision tree dan hubungannya dengan nilai confidence
- Analisis jenis decision tree apa saja yang digunakan dan mengapa perlu dilakukan pada dataset tersebut

b. Bayesian Classification

Thomas Bayes memperkenalkan sebuah proses klasifikasi dengan menggunakan metode probabilistic dan statistic. Olson dan Delen (2008, p102) menjelaskan Naïve Bayes untuk di setiap tipe keputusan, hitung probabilitas asalkan tipe keputusan itu benar, karena mengingat vektor informasi objek. Pada algoritma ini dapat di asumsikan bahwa properti objek bersifat independen. Pembuatan estimasi akhir dapat dilihat dari probabilitas yang terlibat di dalam

jumlah frekuensi dari sebuah tabel keputusan “utama”.

Naïve Bayes Classifier atau hanya dikenal sebagai polinomial Bayesian adalah penyederhanaan dari algoritma Bayesian yang cocok untuk klasifikasi teks atau dokumen.

Langkah klasifikasi Bayesian adalah:

- 1) Langkah pertama: Hitung $P(v_j) \prod P(w_k | v_j)$ untuk setiap kategori.

Langkah kedua: Tentukan kategori dengan nilai $P(v_j) \prod P(w_k | v_j)$ maksimal

Dimana untuk kategori:

- $P(v_j)$: Probabilitas setiap dokumen terhadap sekumpulan dokumen.
- $P(w_k | v_j)$: Probabilitas kemunculanya kata w_k pada suatu dokumen dengan kategori class v_j .

- 2) Latihan Bayesian Classification

Latihan: Prediksi Kelulusan Mahasiswa menggunakan naïve Bayesian classifier, dengan tahapan:

- Lakukan training pada data mahasiswa (datakelulusanmahasiswa.xls).
- Lakukan pengujian dengan menggunakan 10-fold X Validation

- Uji beda dengan t-Test untuk mendapatkan model terbaik

c. Neural Network

Jaringan syaraf (*Neural network*) atau NN adalah tipe matematika yang mensimulasikan sistem kerja pada jaringan saraf di otak manusia. NN diketahui berhasil menyelesaikan masalah dengan data yang kompleks (tidak pasti), berisik, atau tidak lengkap.

Neural Network dapat memecahkan:

- Masalah yang tidak terstruktur dan sangat sulit didefinisikan, dapat belajar dari pengalaman.
- Mampu untuk memilih suatu input data ke dalam beberapa kategori tertentu yang sudah ditetapkan.
- Mampu untuk menggambarkan suatu objek secara keseluruhan walau dengan data yang tidak lengkap.
- Mempunyai kemampuan dalam mengolah data-data input tanpa harus mempunyai target.
- Mampu untuk menemukan suatu jawaban yang terbaik sehingga mampu meminimalisasi fungsi biaya.

Langkah-langkah penting yang dilakukan *Neural Network* sebagai berikut:

- Menentukan fitur-fitur atau ciri yang dapat memudahkan klasifikasi kelas-kelas, yang akan dijadikan input. Pengetahuan akan fitur kelas-kelas, akan membantu dalam klasifikasi.
- Mengumpulkan data pelatihan yang representatif dengan jumlah yang memadai bila memungkinkan
- Pemilihan model jaringan, dan algoritme pelatihan. Setiap model arsitektur dan algoritme memiliki kelebihan dan kekurangan dalam hal waktu dan akurasi, sehingga pemilihan model neural network bergantung pada factor mana yang lebih diprioritaskan.

Latihan Neural Network seperti tahapan dibawah ini:

- Lakukan training dengan neural network untuk dataset TeamValue Training
- Gunakan 10-fold cross validation
- Lakukan adjusment terhadap hidden layer dan neuron size, misal: hidden layer saya buat 3, neuron size masing-masing 5
- Apa yang terjadi, apakah ada peningkatan akurasi?

Tabel 4. 1 Hidden Layer

	NN	NN (HL 2 NS 3)	NN (HL 2 NS 5)	NN (HL 3 NS 3)	NN (HL 3 NS 5)	NN (HL 4 NS 3)	NN (HL 4 NS 5)
Accuracy							

Tentukan Hidden Layer

Hidden Layer	Capabilities
0	Only capable of representing linear separable functions or decisions
1	Can approximate any function that contains a continuous mapping from one finite space to another
2	Can represent an arbitrary decision boundary to arbitrary accuracy with rational activation functions and can approximate any smooth mapping to any accuracy

Penentuan Neuron Size

1) Trial and Error

Rule of Thumb:

- Between the size of the input layer and the size of the output layer
- $\frac{2}{3}$ the size of the input layer, plus the size of the output layer
- Less than twice the size of the input layer

2) Search Algorithm:

- Greedy
- Genetic Algorithm
- Particle Swarm Optimization
- etc

Model *decision tree* atau model pohon keputusan adalah sebuah model dalam data mining yang umum digunakan dan mudah untuk diinterpretasikan. Urutan pertanyaan yang disusun secara sistematis sehingga setiap pertanyaan menanyakan atribut, atribut pada model decision tree disebut dengan node. Setiap node memiliki cabang dan daun. Cabang pada pohon keputusan merupakan nilai dari atributnya. Pada daun ditempatkan variabel kelas sebagai prediksi. Model *decision tree* ini merupakan pembelajaran terawasi (supervised learning) dimana pohon keputusan

dibangun dari satu set sampel input-output. Sistem pembelajaran pada pohon keputusan mengadopsi strategi *top-down* yang mencari solusi pada bagian ruang pencarian.

d. Model Overfitting

Overfitting adalah kesulitan praktis yang signifikan untuk model pohon keputusan dan banyak model prediktif lainnya. Overfitting terjadi ketika algoritme pembelajaran terus mengembangkan hipotesis yang mengurangi kesalahan set pelatihan dengan mengorbankan kesalahan set pengujian yang meningkat. Ada beberapa pendekatan untuk menghindari overfitting dalam membangun pohon keputusan.



Gambar 4. 1 Model Overfitting

- 1) **Pra-pemangkasan** yang menghentikan pertumbuhan pohon lebih awal, sebelum mengklasifikasikan set pelatihan dengan sempurna.
- 2) **Pasca-pemangkasan** yang memungkinkan pohon mengklasifikasikan set pelatihan dengan sempurna, dan kemudian setelah memangkas pohon.

Secara praktis, pendekatan kedua pohon overfit pasca-pemangkasan lebih berhasil karena tidak mudah untuk memperkirakan secara tepat kapan harus berhenti menumbuhkan pohon. Langkah penting pemangkasan pohon adalah menentukan kriteria yang digunakan untuk menentukan ukuran pohon akhir yang benar menggunakan salah satu metode berikut:

- a. Gunakan set data yang berbeda dari set pelatihan (disebut set validasi), untuk mengevaluasi efek node pasca-pemangkasan dari pohon.

Bangun pohon dengan menggunakan set pelatihan, lalu terapkan uji statistik untuk memperkirakan apakah pemangkasan atau perluasan simpul tertentu kemungkinan akan menghasilkan peningkatan di luar set pelatihan. Estimasi kesalahan, Pengujian signifikansi (misalnya, uji Chi-kuadrat)

Deskripsi Minimum Prinsip panjang: Gunakan ukuran eksplisit kompleksitas untuk mengkodekan set

pelatihan dan pohon keputusan, menghentikan pertumbuhan pohon ketika ukuran penyandian (ukuran(pohon) + ukuran (misklasifikasi(pohon)) ini diminimalkan. Metode pertama adalah pendekatan yang paling umum. Dalam pendekatan ini, data yang tersedia dipisahkan menjadi dua set.

contoh: set pelatihan, yang digunakan untuk membangun pohon keputusan, dan set validasi, yang digunakan untuk mengevaluasi dampak pemangkasan pohon. Metode kedua juga merupakan pendekatan umum.

Berikut kami jelaskan estimasi error dan uji Chi 2.

$$e = \left(f + \frac{z^2}{2N} + z \sqrt{\frac{f}{N} - \frac{f^2}{N} + \frac{z^2}{4N^2}} \right) / \left(1 + \frac{z^2}{N} \right)$$

Where:


- f is the error on the training data
- N is the number of instances covered by the leaf
- z from normal distribution

b. Pasca-pemangkasan menggunakan estimasi Kesalahan

Estimasi kesalahan untuk subpohon adalah jumlah tertimbang dari estimasi kesalahan untuk semua daunnya. Estimasi kesalahan (e) untuk sebuah node adalah:

Dalam contoh berikut, kami menetapkan Z ke 0,69 yang sama dengan tingkat kepercayaan 75%.

Tingkat kesalahan pada simpul induk adalah 0,46 dan karena tingkat kesalahan untuk anak-anaknya (0,51) meningkat dengan pemisahan, kami tidak ingin mempertahankan anak-anak.



Pasca pemangkasan menggunakan uji Chi ²

Dalam uji Chi ² kami membuat tabel frekuensi yang sesuai dan menghitung nilai Chi ² dan probabilitasnya.

Jika kita mensyaratkan bahwa probabilitas harus kurang dari batas (misalnya, 0,05), maka kita memutuskan untuk tidak membagi node.

	Perunggu	Perak	Emas
Buruk	4	1	4
Bagus	2	1	2

Chi ² = 0,21 Probabilitas = 0,90 derajat kebebasan = 2

C. Latihan

1. Apa yang dimaksud dengan Klasifikasi?
2. Sebutkan 4 kelompok utama dari algoritma klasifikasi table frekuensi?
3. Apa yang dimaksud dengan Model Decision Tree?

Di bawah ini adalah tabel dengan data pelatihan database karyawan. Data ini telah digeneralisasi. Misalnya, "31...35" untuk usia berarti antara 31 dan 35 tahun. Khususnya kolom "jumlah" menunjukkan jumlah set dari setiap data tentang departemen, status, usia, gaji pada baris yang sedang dipertimbangkan.

Department	Status	Usia	Gaji	Jumlah
Sales	Senior	31. . . 35	46K. . . 50K	30
Sales	Junior	26. . . 30	26K. . . 30K	40
Sales	Junior	31. . . 35	31K. . . 35K	40
Systems	Junior	21. . . 25	46K. . . 50K	20
Systems	Senior	31. . .	66K. . .	5

		35	70K	
Systems	Junior	26. . . 30	46K. . . 50K	3
Systems	Senior	41. . . 45	66K. . . 70K	3
Marketing	Senior	36. . . 40	46K. . . 50K	10
Marketing	Junior	31. . . 35	41K. . . 45K	4
Secretary	Senior	46. . . 50	36K. . . 40K	4
Secretary	Junior	26. . . 30	26K. . . 30K	6

4. Buatlah decision tree menurut teknik anda

Buatlah rules-based classification berdasarkan decision tree tersebut.

X adalah suatu data/tuple baru dengan nilai sbb:

X = (dept = systems; usia = 26...30; gaji = 46-50k)

Menurut naive bayesian classification apakah status/class label dari data/tuple X tersebut?

D. Referensi

- Gede, A., Pradnyana, S., Kom, M., Kom, K., Agustini, S., & Si, M. (t.thn.). *Konsep Dasar Data Mining*.
- Jawad, M., & Mughal, H. (2018). *Data Mining: Web Data Mining Techniques, Tools and Algorithms: An Overview*. Diambil kembali dari www.ijacsa.thesai.org
- Putra, P., H Pardede, A. M., & Syahputra, S. (2022). ANALISIS METODE K-NEAREST NEIGHBOUR (KNN) DALAM KLASIFIKASI DATA IRIS BUNGA. *Jurnal Teknik Informatika Kaputama (JTIK)*, 6(1).
- Rinna Rachmatika, A. (2020). Perbandingan Model Klasifikasi untuk Evaluasi Kinerja Akademik Mahasiswa. *Jurnal Edukasi dan Penelitian Informatika*, 1-6.
- Suntoro, J., & Kom, M. (t.thn.). *DATA MINING Algoritme dan Implementasi Menggunakan Bahasa Pemrograman PHP*.