

# BAB II

## DATA

---

### A. Capaian Pembelajaran

Pada pertemuan kali ini diharapkan mahasiswa/i dapat menjelaskan tentang:

1. Definisi Data
2. Jenis Data
3. Kualitas Data
4. Preprocessing Data
5. Teknik Pengukuran Data

### B. Materi

#### 1. Definisi Data

Data adalah kumpulan informasi atau fakta yang terdiri dari kata, frase, simbol, angka dan sejenisnya. Data disini diperoleh melalui proses penelitian serta observasi yang akurat berdasarkan sumber-sumber tertentu. Cara lain untuk memahami data adalah mengumpulkan informasi dasar atau deskriptif tentang suatu objek atau peristiwa.

Contoh pengumpulan informasi yang diperoleh dari pengamatan kemudian diubah menjadi bentuk kompleks lainnya. Baik berupa informasi, database dan lain-lain. Data dari sudut bahasa kata berasal dari sebuah kata Latin yang berarti "*Datum*" yaitu suatu informasi yang siap diberikan. Dari istilah ini kita dapat menemukan arti dari data yang diperoleh dari pengukuran atau pengamatan terhadap variabel tertentu yang berupa kata, warna, angka, simbol dan informasi lainnya.

Data itu sendiri masih mentah. Oleh karena itu, jika ingin mendapatkan data yang akurat dan berkualitas. Kita harus mengandalkan data yang dapat diandalkan karena keaslian, keakuratan, ketepatan waktu, dan cakupannya yang luas sangat penting. Selain itu, karena data bersifat mentah, tidak ada yang dapat membaca dan melihatnya untuk mendapatkan informasi yang lengkap. Tidak heran jika dari data tersebut kita masih perlu mengolah data yang diperoleh agar data tersebut benar-benar menghasilkan informasi yang mudah kita pahami.

## 2. Jenis Data

Berikut adalah beberapa tipe data, diantaranya:

### a. Data Berdasarkan Cara Mendapatkannya

Tipe data pertama didasarkan pada bagaimana data itu diperoleh. Ada 2 (dua) cara untuk mendapatkan data, antara lain sebagai berikut:

- 1) Data primer adalah data yang dikumpulkan secara langsung dari subyek yang telah diteliti oleh organisasi maupun individu.

Misalnya: Data dari hasil survei, data dari hasil wawancara, data dari hasil kuesioner.

- 2) Data sekunder adalah data yang dapat kita ambil dari data primer. Artinya dalam bentuk data sekunder tidak perlu mengumpulkan data secara langsung dari subjek penelitian. Seringkali jenis data ini dapat diperoleh dari penelitian sebelumnya yang telah dilakukan. Dalam bentuk bagan, tabel dan diagram.

Contohnya adalah: Data penyakit tertentu, data sensus, dll.

### b. Data Berdasarkan Sumber

Jenis data yang satu ini memiliki dua macam, yaitu:

- 1) Data Eksternal adalah data yang diperoleh dari pihak luar, dimana penelitian itu dilakukan. Biasanya, jenis data ini digunakan sebagai

pembandingan suatu tempat dengan tempat lainnya. Misalnya saja data kependudukan, data penjualan produk perusahaan lain, data jumlah siswa dari sekolah lain, dan lain sebagainya.

- 2) Data Internal adalah data yang bisa diperoleh langsung dari suatu tempat berlangsungnya penelitian itu. Misalnya saja, data karyawan dari sebuah perusahaan, data mengenai kepuasan pelanggan suatu perusahaan dan lain sebagainya.

#### c. Data Berdasarkan Sifat

Tipe data dibedakan berdasarkan sifat-sifatnya, antara lain data kuantitatif dan data kualitatif.

- 1) Data Kuantitatif (*quantitative data*) adalah data yang berbentuk angka. Data kuantitatif ini merupakan jenis data yang diperoleh dan dikumpulkan dengan melakukan survey. Dari survei ini akan diperoleh hasil data berupa angka dan data kuantitatif yang merupakan jenis data objektif. Contoh data kuantitatif jenis ini meliputi jumlah pengguna aplikasi, usia pelanggan produk tertentu, suhu tubuh, tinggi badan, jumlah siswa di sekolah, dan lainnya.
- 2) Data Kualitatif (*qualitative data*) adalah data berupa kata deskriptif yang menjelaskan suatu makna. Data yang dihasilkan tidak berbentuk

digital melainkan berupa gambar, simbol, kata-kata dan bentuk data verbal lainnya. Data ini dapat diperoleh melalui observasi, pengisian angket, penelitian kepustakaan, wawancara, dll.

d. Data Berdasarkan Waktu Pengumpulannya

Kriteria tipe data berikutnya adalah tipe data yang berbeda tergantung kapan dikumpulkan. Ada dua jenis data, yaitu data silang dan data periodik.

- 1) Data *cross sectional* adalah data yang dikumpulkan pada waktu tertentu dan menunjukkan waktu tertentu untuk memperoleh informasi tentang subjek penelitian pada waktu itu. Misalnya saja, data penelitian kuesioner.
- 2) Data *periodically* adalah data yang dikumpulkan secara berkala dari waktu yang berbeda untuk mengetahui suatu perubahan yang terjadi dari sebuah peristiwa selama periode tertentu. Misalnya saja data harga makanan.

### 3. Kualitas Data

Kualitas data (*data quality*) adalah pengembangan dan implementasi kegiatan yang menerapkan teknik manajemen kualitas pada data. Tujuannya adalah untuk memastikan bahwa informasi disesuaikan untuk memenuhi kebutuhan spesifik organisasi dalam konteks tertentu. Tentunya dengan data berkualitas tinggi, tidak

akan ada masalah kualitas data seperti data duplikat, data tidak lengkap, data tidak konsisten, data salah, data tidak jelas, data tidak terorganisir dengan baik atau keamanan data buruk.

Penilaian kualitas data dilakukan oleh analis kualitas data, yang tugasnya mengevaluasi dan menginterpretasikan setiap indikator kualitas data, memberikan skor pada kualitas data secara keseluruhan, dan mempresentasikan tingkat keakuratan data perusahaan. Scorecard dengan data berkualitas rendah menunjukkan kualitas data yang buruk, nilai yang kecil, dan dapat menyebabkan pengambilan keputusan yang buruk yang merugikan bisnis. Aturan kualitas data adalah bagian penting dari manajemen data. Ini adalah proses mengembangkan dan menegakkan seperangkat aturan dan standar yang mengatur semua informasi bisnis. Manajemen data yang efektif memerlukan pengumpulan data dari berbagai sumber data, menetapkan dan memantau kebijakan penggunaan data, serta menghilangkan ketidakkonsistenan dan kesalahan. Jika hal ini tidak dilakukan dengan benar, akan berdampak negatif terhadap keakuratan analisis data dan kepatuhan terhadap peraturan.

Mengapa kualitas informasi penting? Jawabannya sederhana karena data yang buruk dapat berakibat serius bagi bisnis. Data berkualitas buruk dapat menjadi

sumber penipuan operasional, analitik yang tidak akurat, dan strategi perdagangan yang tidak efektif.

Masalah kualitas data dapat menyebabkan kerugian besar. Misalnya, biaya tambahan saat produk dikirimkan ke alamat pelanggan yang salah, kehilangan pendapatan karena informasi pelanggan yang tidak lengkap, penalti karena pelaporan keuangan atau kepatuhan yang salah.

Dalam menilai data quality, setidaknya ada lima dimensi yang wajib untuk dipertimbangkan. Berikut ini penjelasannya:

a. Ketepatan (*Accuracy*)

Seperti namanya, *Accuracy* berarti informasi yang akurat dalam data. Untuk menentukan apakah data akurat, tanyakan pada diri Anda apakah informasi tersebut mencerminkan situasi kehidupan nyata. *Accuracy* adalah karakteristik penting dari kualitas data, karena informasi yang tidak akurat dapat menyebabkan masalah dan konsekuensi yang serius.

b. Kelengkapan (*Completeness*)

Kelengkapan mengacu pada kelengkapan informasi yang tersedia untuk Anda. Faktor penting dalam kelengkapan data adalah memastikan semua data yang Anda butuhkan tersedia. Ukuran penuh

penting karena jika informasinya tidak lengkap, datanya bisa menjadi tidak dapat digunakan.

c. Keandalan (*Reliability*)

Keandalan berarti bahwa informasi tidak bertentangan dengan informasi lain dari sumber atau sistem yang berbeda. Sebagai fitur penting dari kualitas data, ketika potongan informasi bertentangan, Anda tidak dapat mempercayai data tersebut. Penggunaannya dapat menyebabkan kesalahan yang mahal dan merusak reputasi perusahaan.

d. Relevansi (*Relevance*)

Relevansi berfungsi karena harus ada alasan yang baik bagi Anda untuk mengumpulkan informasi tertentu sejak awal. Tentukan apakah Anda benar-benar membutuhkan informasi tersebut. Relevansi penting karena jika Anda mengumpulkan informasi yang tidak relevan, Anda hanya akan membuang waktu dan uang. Analisis data juga akan sia-sia.

e. Ketepatan Waktu (*Timeliness*)

Ketepatan waktu mengacu pada ketepatan waktu informasi yang tersedia untuk Anda. Ketepatan waktu informasi merupakan aspek penting dari kualitas data karena informasi yang tidak tepat waktu dapat menyebabkan orang mengambil keputusan

yang salah. Dampaknya adalah waktu, uang dan rusaknya reputasi perusahaan.

#### 4. Preprocessing Data

Pemrosesan awal data melibatkan konversi data mentah menjadi format yang mudah dimengerti. Proses ini penting karena data mentah seringkali tidak dalam format biasa. Selain itu, data mining tidak bisa mengolah data mentah, sehingga proses ini penting untuk mempermudah proses selanjutnya yaitu analisis data.

Setelah mengetahui tentang apa itu data preprocessing, ada beberapa step yang perlu dilakukan ketika akan melakukan data preprocessing.

Berikut ini adalah langkah-langkah preprocessing data:

- a. Pembersihan Data (*Data Cleansing*) adalah data yang kotor atau tidak lengkap menyebabkan hasil yang buruk dan kegagalan sistem yang menghabiskan waktu dan uang. data yang tidak lengkap dan salah akan dihapus dari pendataan.

Ada 5 langkah dalam proses pembersihan data;

- 1) Identifikasi Data (*Identify Data*)
- 2) Perbaiki Kesalahan Struktural (*Fix Structural Mistakes*)

- 3) Atur Teknik Pembersihan Data (Set Data Cleansing Techniques)
- 4) Filter Pencilan dan Perbaiki Data yang Hilang (*Filter Outliers and Fix Missing Data*)
- 5) Menerapkan Proses (Implement Processes)




**Gambar 2. 1** Data Clening Process

b. Integrasi Data (*Data Integration*) adalah proses menggabungkan data dari sumber yang berbeda menjadi satu kesatuan. Integrasi dimulai dengan proses penyerapan, dan mencakup langkah-langkah seperti pembersihan, pemetaan ETL, dan transformasi data untuk menghasilkan intelijen bisnis yang efektif dan dapat ditindaklanjuti.

Ada 4 langkah dalam proses integrasi data;

- 1) Pengumpulan data dari berbagai sumber.
- 2) *Data Filtering* / Proses pembersihan data
- 3) Pemetaan ETL (*Extract, Transform, and Load*)


#### 4) Implementasi



**Gambar 2. 2** Data Integration Process

- c. Pemilihan data (*Data Selection*) adalah proses memilih atau menyaring sebuah data yang relevan untuk dianalisis dan diperoleh dengan berbagai kumpulan data yang ada.
- d. Data Transformation (*Data Transformation*), proses transformasi data terpilih menjadi proses data mining dengan menggunakan data aktif dan penggabungan dalam bentuk lain sehingga data tersebut memiliki sebaran yang diharapkan.
- e. Penambangan data (*Data Mining*) adalah proses terpenting dalam tahap ini, di mana teknik yang berbeda akan diterapkan untuk mengekstraksi pola potensial yang berbeda untuk mendapatkan data yang berguna.

- f. Evolusi Pola (*Pattern Evolution*) adalah Suatu proses di mana informasi menarik sebelumnya ditemukan dengan menentukannya berdasarkan pengukuran tertentu.
- g. Presentasi Pengetahuan (*Knowledge Presentation*) adalah merupakan langkah terakhir untuk memproses data mining. Dengan hal ini digunakan teknik visualisasi yang bertujuan untuk mempermudah pengguna menginterpretasikan hasil pencarian data.



**Gambar 2. 3** Preprocessing Data Mining

Preprocessing data mining penting karena dapat menghadirkan fitur dan manfaat pada data mining. Proses ini dilakukan terutama untuk memastikan bahwa data memiliki kualitas yang baik sebelum digunakan

dalam analisis data. Dalam proses ini, Anda dapat menjamin enam hal, yaitu akurasi, kelengkapan, konsistensi, ketepatan waktu, keandalan, dan interpretasi data.

Jika data sudah diolah berdasarkan enam referensi, akan lebih mudah untuk menganalisis data karena data dari banyak sumber yang berbeda terkandung dalam satu kumpulan data dengan format yang sama.

## **5. Teknik Pengukuran Data**

Pengukuran data merupakan topik penting yang sangat perlu dibahas karena memiliki pengaruh besar terhadap keberhasilan penelitian. Skala merupakan alat atau mekanisme penting untuk membedakan individu menjadi variabel dalam penelitian. Skala data merupakan bagian penting dari metodologi penelitian yang memiliki beberapa kategori atau kategori yang umum dan sering terdengar, yaitu:

skala nominal, skala ordinal, skala interval, dan skala proporsional.

### **a. Skala Nominal**

Skala nominal merupakan jenis pengukuran yang paling sederhana, dimana angka yang melekat pada suatu benda dianggap sebagai label atau tanda yang membedakan satu benda dengan benda

lainnya. Biasanya, skala nominal digunakan untuk menjelaskan atau mendefinisikan status responden atau mengkategorikan sekelompok responden, misalnya laki-laki (laki-laki) dan perempuan (perempuan). Skala nominal adalah skala yang hanya memiliki satu nilai kategorikal, dalam statistik disebut kategorikal yang tidak dapat berperan sebagai nilai yang dapat dihitung.

b. Skala Ordinal

Skala ordinal adalah skala yang menyatakan posisi atau urutan suatu bilangan. Biasanya skala ini digunakan untuk memberikan pilihan arah jawaban yang diinginkan kepada responden atau sampel penelitian. Contoh yang sangat buruk, tidak baik, cukup baik, baik, sangat baik. Skala ini mirip dengan skala nominal yang memberikan nilai kategorikal dan ordinal pada objek tetapi skala ordinal memiliki tingkatan data karena ada data orde tinggi dan data orde rendah.

c. Skala Interval

Skala interval adalah jenis skala yang tidak hanya memberikan informasi referensial tentang urutan atau hirarki dari suatu objek, tetapi juga memberikan informasi terkait penting tentang jarak antara urutan tersebut. Skala ini berbeda seratus delapan puluh derajat dari skala skala, yang berarti tidak menentukan nilai nol sebagai dasar

pengukurannya, jadi 0 tidak memiliki atau bukan titik referensi nol mutlak.

d. Skala Rasio

Skala rasio adalah kebalikan dari skala interval, yaitu menetapkan titik nol atau nol mutlak sehingga nilai nol benar-benar dapat diinterpretasikan. Angka 0 akan dianggap sebagai angka, yang merupakan faktor dasar untuk menghitung dan mengukur dalam suatu penelitian.

**Tabel 2. 1** Kegunaan Pengukuran Skala Secara Matematis dan Statistik

| Skala    | Operasi Numerik                                 | Operasi Statistik                        |
|----------|-------------------------------------------------|------------------------------------------|
| Nominal  | Perhitungan                                     | Frekuensi, Modus                         |
| Ordinal  | Penyusunan Peringkat                            | Median, Range, Percentile                |
| Interval | Perhitungan Aritmatik pada Angka-angka Interval | Mean, Standar Deviasi, Varians           |
| Rasio    | Perhitungan Aritmatik pada Angka-angka Aktual   | Mean Geometric, Coefficient of Variation |

### **C. Latihan**

1. Jelaskan mengenai data primer dan data sekunder!
2. Sebutkan 5 nama dalam menilai data quality!
3. Apa itu preprocessing data?
4. Sebutkan 5 preprocessing data mining!

#### **D. Referensi**

- Gede, A., Pradnyana, S., Kom, M., Kom, K., Agustini, S., & Si, M. (n.d.). *Konsep Dasar Data Mining*.
- Jawad, M., & Mughal, H. (2018). *Data Mining: Web Data Mining Techniques, Tools and Algorithms: An Overview*. Retrieved from [www.ijacsa.thesai.org](http://www.ijacsa.thesai.org)
- Putra, P., H Pardede, A. M., & Syahputra, S. (2022). ANALISIS METODE K-NEAREST NEIGHBOUR (KNN) DALAM KLASIFIKASI DATA IRIS BUNGA. *Jurnal Teknik Informatika Kaputama (JTIK)*, 6(1).
- Rinna Rachmatika, A. (2020). Perbandingan Model Klasifikasi untuk Evaluasi Kinerja Akademik Mahasiswa. *Jurnal Edukasi dan Penelitian Informatika*, 1-6.
- Suntoro, J., & Kom, M. (n.d.). *DATA MINING Algoritme dan Implementasi Menggunakan Bahasa Pemrograman PHP*.