

BAB III

EKSPLORASI DATA

A. Capaian Pembelajaran

Pada pertemuan kali ini diharapkan mahasiswa/i dapat menganalisa tentang:

1. Statistik Data.
2. Visualisasi Data.
3. OLAP Dan Analisis Data Multi Dimensional.

B. Materi

1. Statistik Data

Statistik data mempelajari pengumpulan, analisis, interpretasi atau interpretasi dan penyajian data. Penambangan data memiliki hubungan yang melekat dengan statistik. Model statistik adalah seperangkat fungsi matematika yang menggambarkan perilaku objek dari kelas target menurut variabel acak dan distribusi probabilitas yang terkait. Model statistik banyak digunakan untuk memodelkan data dan kelas data. Misalnya, dalam tugas penambangan data seperti


deskripsi dan klasifikasi data, model statistik dari kelas target dapat dibangun. Dengan kata lain, model statistik semacam itu bisa jadi merupakan hasil dari tugas penambangan data. Atau, tugas penambangan data dapat dibangun di atas model statistik. Misalnya, kita dapat menggunakan statistik untuk memodelkan derau dan nilai data yang hilang. Kemudian, saat menemukan pola dalam kumpulan data besar, proses penambangan data dapat menggunakan pola tersebut untuk membantu mengidentifikasi dan menyelesaikan nilai yang tidak jelas atau hilang dalam data.

Penelitian statistik mengembangkan alat prediksi dan peramalan menggunakan data dan model statistik. Metode statistik dapat digunakan untuk meringkas atau menggambarkan kumpulan data. Statistik berguna untuk mengekstraksi pola yang berbeda dari data dan untuk memahami mekanisme yang mendasari pembentukan dan pengaruh pola. Statistik inferensial (atau statistik prediktif) memodelkan data dengan cara yang menjelaskan keacakan dan ketidakpastian dalam pengamatan dan digunakan untuk menarik kesimpulan tentang proses atau populasi yang sedang dipelajari.

Metode statistik juga dapat digunakan untuk memverifikasi hasil data mining. Misalnya, setelah model klasifikasi atau prediksi ditambang, model tersebut harus diverifikasi dengan pengujian hipotesis statistik. Uji hipotesis statistik (kadang-kadang disebut

analisis data konfirmatori) membuat keputusan statistik menggunakan data eksperimen. Suatu hasil disebut signifikan secara statistik jika tidak mungkin terjadi secara kebetulan. Jika klasifikasi atau model prediksi berlaku, maka statistik deskriptif model meningkatkan kesehatan model.

Menerapkan metode statistik dalam data mining jauh dari hal yang sepele. Seringkali, tantangan serius adalah bagaimana meningkatkan metode statistik pada kumpulan data yang besar. Banyak metode statistik memiliki kompleksitas yang tinggi dalam komputasi. Ketika metode tersebut diterapkan pada kumpulan data besar yang juga didistribusikan di beberapa situs logis atau fisik, algoritma harus dirancang dan disetel dengan hati-hati untuk mengurangi biaya komputasi. Tantangan ini menjadi lebih berat untuk aplikasi online, seperti saran kueri online di mesin pencari, di mana penambahan data diperlukan untuk terus menangani aliran data nyata yang cepat.



Gambar 3. 1 Contoh Data Statistik Pegawai Berdasarkan Golongan

2. Visualisasi Data

Visualisasi data adalah tampilan grafis atau visual dari informasi dan data. Dengan kata lain, visualisasi data mengubah kumpulan data menjadi sesuatu yang lebih mudah dilihat. Dengan menggunakan visualisasi ini, pembaca dapat dengan mudah memahami tren, outlier, dan pola dalam data, serta membuat keputusan yang lebih mudah dan akurat.


Berikut adalah tipe visualisasi data:

a. Tipe Visualisasi Temporal

Visualisasi temporal adalah salah satu tipe visualisasi yang paling populer. Tipe ini hanya cocok untuk menampilkan hasil dari dataset linier atau satu

dimensi. Ciri utama visualisasi jenis ini berupa garis yang berawal dan berakhir di titik tertentu. Garis-garis ini dapat berdiri sendiri atau bersinggungan dengan garis lainnya.

Contoh visualisasi data seperti ini adalah *diagram scatterplot*, *timeline*, *data time series*, dan diagram garis.




Gambar 3. 2 Contoh Tipe Visualisasi Temporal

b. Tipe Visualisasi Hierarki

Tipe visualisasi hierarki ini sering digunakan untuk menyatakan hubungan antara suatu kelompok dengan kelompok lain yang lebih besar. Visualisasi seperti itu cocok untuk menunjukkan munculnya data baru dari suatu penyebab. Salah satu penggunaan yang umum adalah diagram pohon, seperti gambar berikut.

d. Tipe Visualisasi Multidimensi

Seperti namanya, tipe visualisasi multidimensi berarti cocok untuk memvisualisasikan data dengan banyak variabel atau dimensi. Karena banyaknya kumpulan data yang ditampilkan, visualisasi ini seringkali lebih menarik dan mencolok agar lebih mudah dipahami. Contoh visualisasi ini adalah bagan kolom, bagan pai, dan batang bertumpuk.




Gambar 3. 5 Contoh Tipe Visualisasi Multidimensional

e. Tipe Visualisasi Geospasial

Tipe terakhir dari visualisasi data adalah geospasial. Pada tipe ini, visualisasi merepresentasikan bentuk sebenarnya dari suatu objek atau ruang data yang akan ditampilkan. Secara umum, visualisasi geospasial biasa digunakan untuk

menunjukkan penetrasi penjualan di suatu area, untuk memetakan pertumbuhan bisnis, untuk menunjukkan aliran dalam UX. Contoh visualisasi geospasial yang paling sering digunakan adalah heatmap dan kartograf.



Gambar 3. 6 Contoh Tipe Visualisasi Geospasial

3. Analisis Data Multi Dimensional OLAP

OLAP (*Online Analytical Processing*) adalah alat online yang digunakan untuk melakukan analisis data multidimensi dan menyediakan komputasi tingkat lanjut, analisis tren, dan kemampuan pemodelan data. Sebelum melakukan analisis data, kami biasanya mengumpulkan dan mengkategorikan data yang diperlukan terlebih dahulu dan kemudian

menggabungkannya. Dengan menggunakan OLAP, Anda dapat melakukannya dengan lebih mudah dan lebih cepat. OLAP akan membagi data menjadi beberapa bagian, yang kemudian akan dirancang untuk membentuk sebuah laporan.

Fitur utama yang disediakan oleh aplikasi ini adalah konsep kubus. Blok OLAP adalah struktur data yang dioptimalkan untuk analisis data yang sangat cepat. Data akan dimasukkan ke dalam sel dan akan disajikan dalam spreadsheet 3D untuk membentuk kubus. ini memfasilitasi visualisasi dan memfasilitasi analisis data. Data akan diekstraksi dari data warehouse, kemudian data tersebut akan dimasukkan ke dalam proses pembersihan data, kemudian data tersebut akan diimpor ke server OLAP atau blok OLAP. Data yang diimpor kemudian akan masuk ke proses analisis. 5 Fitur Basis Data OLAP.

OLAP memiliki lima teknik yang dapat diringkas menjadi FASMI (Fast Analysis of Shared Multi-dimensional Information). Hal Ini lebih mudah dipahami dan diingat. Dan inilah penjelasannya:

a. Fast

Tujuan dari sistem ini adalah untuk menanggapi pengguna secepat mungkin berdasarkan analisis.

b. Analysis

Sistem dapat memproses berbagai logika bisnis dan analisis statistik yang relevan dengan aplikasi dan pengguna.

c. Shared

Sistem memenuhi semua persyaratan keamanan informasi. Jika banyak hak tulis diperlukan untuk data, itu harus disesuaikan tergantung pada level pengguna. Karena tidak semua aplikasi mengharuskan pengguna untuk menulis ulang data, sistem harus dapat melakukan banyak pembaruan secara bersamaan dengan aman.

d. Multidimensional

Sistem harus memberikan pandangan konseptual dari data dengan cara multidimensi, dan dukungan hierarki penuh dan dukungan hierarki ganda. Ini adalah cara yang logis untuk melakukan analisis bisnis dan organisasi.

e. Information

Semua informasi dan data yang diperlukan dan penting untuk aplikasi. Produk OLAP tidak sama kemampuannya dalam mengolah data input, yang bergantung pada beberapa aspek, yaitu: Replikasi data, penggunaan ruang disk, penggunaan RAM, kinerja, integrasi layanan data, dll.

Membuat sebuah array multidimensi ada 2 (dua)
Langkah dalam mengonversi data tabular menjadi array multidimensi:

f. Identifikasi atribut mana yang merupakan atribut dimensi dan mana atribut target/target yang nilainya muncul sebagai entri dalam array multidimensi:

- Atribut yang digunakan sebagai dimensi adalah nilai diskrit.
- Nilai target biasanya berupa nilai konstan, misalnya harga suatu item.
- Tidak memiliki nilai target sama sekali, selain jumlah objek yang memiliki himpunan yang sama dengan nilai atribut.

Temukan nilai setiap entri dalam array multidimensi dengan menjumlahkan nilai (dari atribut target) atau dengan mendaftar semua objek yang nilai atributnya cocok dengan entri tersebut.

Contoh: Data Bunga Irisan.



Gambar 3. 7 Bunga Irisan

Dengan menggunakan data - data berikut, akan membahas bagaimana panjang tajuk, lebar tajuk, dan atribut spesies dapat diubah menjadi array multidimensi.


- g. Kami memisahkan lebar dan panjang tajuk untuk mendapatkan kategori: low, medium and high maka akan diperoleh tabel sebagai berikut:

Tabel 3. 1 Tabel Kategori Bunga Irisan

Panjang tajuk	Lebar tajuk	Type Spesies	Jumlah
Low	Low	Sentosa	46
Low	Medium	Sentosa	2
Medium	Low	Sentosa	2
Medium	Medium	Vercicolour	43
Medium	Medium	Vercicolour	3
Medium	High	Virginica	3
High	Medium	Vercicolour	2
High	Medium	Virginica	3
High	High	Vercicolour	2

High	High	Virginica	44
------	------	-----------	----

Gambar 3. 8 Kubus Data



- Setiap lebar tajuk individu, panjang tajuk dan tipe spesies mewakili elemen array
- Elemen ini menunjukkan korespondensi penjumlahan
- Semua tuple yang tidak dispesifikasikan adalah nol
- Gambar 3.8 di bawah ini menjelaskan hal tsb

Irisan array multidimensi ditunjukkan pada tabel berikut. Apa sebenarnya yang ingin ditunjukkan oleh tabel berikut?

Tabel 3. 2 Tabel Array


Length	Widht			
	Low		Medium	High
	Low	46	2	0
	medium	2	0	0
	high	0	0	0

Length	Widht			
	Low		Medium	High
	Low	46	2	0
	medium	2	0	0
	high	0	0	0

Length	Widht			
	Low		Medium	High
	Low	46	2	0
	medium	2	0	0
	high	0	0	0

Fungsi utama OLAP adalah pembuatan kubus data. Kubus data adalah representasi data multidimensi bersama dengan semua kemungkinan angka, yaitu. sekumpulan kemungkinan yang dihasilkan dari proses pemilihan subhimpunan dimensi dan menjumlahkan semua dimensi yang tersisa. Misalnya, jika kita memilih dimensi spesies dari semua data iris, hasilnya akan memiliki dimensi total satu dan jumlah yang mencakup satu dimensi. berisi beberapa bunga dari setiap spesies.

Misalkan dataset berisi penjualan produk dari beberapa perusahaan/toko retail selama beberapa hari. Array 3 dimensi pada data dapat direpresentasikan dan ditunjukkan dengan gambar kubus data berikut ini.



Gambar 3. 9 Kubus Data

Ada tiga himpunan dua dimensi (3 pilih 2) 3 himpunan satu dimensi dan 1 himpunan non dimensi (total semua). Tabel berikut menunjukkan salah satu himpunan dua arah, serta himpunan satu arah dan jumlahnya

	date				total
	Jan 1, 2004	Jan 2, 2004	...	Dec 31, 2004	
product ID					
1	\$1,001	\$987	...	\$891	\$370,000
⋮	⋮			⋮	⋮
27	\$10,265	\$10,225	...	\$9,325	\$3,800,020
⋮	⋮			⋮	⋮
total	\$527,362	\$532,953	...	\$631,221	\$227,352,127

Tabel 3. 3 Tabel agregat two-dimensional

C. Latihan

1. Jelaskan definisi mengenai *data visualization*!
2. Sebutkan 5 (lima) type visualisasi data!
3. Sebutkan apa saja visualisasi data multidimensional!
4. Apa yang dimaksud dengan OLAP?
5. Sebutkan 5 (lima) teknik OLAP!

D. Referensi

- Gede, A., Pradnyana, S., Kom, M., Kom, K., Agustini, S., & Si, M. (n.d.). *Konsep Dasar Data Mining*.
- Jawad, M., & Mughal, H. (2018). *Data Mining: Web Data Mining Techniques, Tools and Algorithms: An Overview*. Retrieved from www.ijacsa.thesai.org
- Putra, P., H Pardede, A. M., & Syahputra, S. (2022). ANALISIS METODE K-NEAREST NEIGHBOUR (KNN) DALAM KLASIFIKASI DATA IRIS BUNGA. *Jurnal Teknik Informatika Kaputama (JTIK)*, 6(1).
- Rinna Rachmatika, A. (2020). Perbandingan Model Klasifikasi untuk Evaluasi Kinerja Akademik Mahasiswa. *Jurnal Edukasi dan Penelitian Informatika*, 1-6.
- Suntoro, J., & Kom, M. (n.d.). *DATA MINING Algoritme dan Implementasi Menggunakan Bahasa Pemrograman PHP*.