

BAB XII

LANJUTAN CLUSTERING

A. Capaian Pembelajaran

Pada pertemuan ini mahasiswa/i diharapkan dapat menganalisa:

1. Definisi DBSCAN
2. Konsep Kepadatan DBSCAN
3. Cluster DBSCAN
4. Metode Evaluasi Clustering

B. Materi

1. Definisi DBSCAN

DBSCAN merupakan algoritma pengelompokan yang dikembangkan berdasarkan kepadatan data (density-based). Dengan demikian, algoritme ini memperluas wilayah padat menjadi kluster dan menemukan kluster tersebut dalam bentuk bebas menggunakan derau dari ruang basis data. Metode ini menggunakan noise untuk merepresentasikan area

yang kurang padat pada objek ruang data, Digunakan untuk membedakan satu cluster dari yang lain. Saat menentukan cluster, DBSCAN menggunakan kerapatan maksimum yang ditemukan dari titik-titik yang terkait dengan Eps dan MinPts adalah parameter. Parameter eps dapat digunakan untuk memperhitungkan jarak maksimum antara titik kelompok cluster dengan pusat. Selain itu, sejumlah titik yang menjadi kelompok di dalam cluster dalam skala radius eps dibatasi oleh parameter MinPts.

(DBSCAN) menumbuhkan daerah yang cukup padat menjadi kelompok dan menemukan kelompok berbentuk acak dalam database spasial yang berisi kebisingan. Sebuah cluster adalah jumlah terbesar dari titik kepadatan yang terhubung, menurut DBSCAN. Kebisingan dianggap sebagai objek apa pun yang bukan dimiliki oleh cluster tersebut.


2. Konsep Kepadatan DBSCAN

DBSCAN menentukan jumlah cluster yang akan dihasilkan, untuk itu dibutuhkan dua input tambahan agar kita tidak perlu lagi menentukan jumlah cluster yang diinginkan. Berikut dua input tambahan yaitu:

- a. MinPts: suatu cluster yang memiliki banyak items minimal.

Eps: Suatu titik items yang menjadi dasar pembentukan yang di dalamnya terapat nilai untuk jarak antar-items neighborhood.


Objek data yang terletak di dalam sebuah radius (ϵ)neighborhood, dapat disebut ϵ -neighborhood. Suatu objek yang terletak di dalam ϵ neighborhood dapat dikatakan sebagai object inti jika suatu objek memiliki setidaknya jumlah MinPts tertentu. Lingkungan fokus garis mengandung jauh lebih sedikit hal daripada lingkungan tempat pusat. Titik garis mungkin menggabungkan lebih dari 1 item tengah. Untuk memperlihatkan bagian mana yang merupakan border point dan bagian mana yang merupakan core point, berikut ini adalah contoh gambar dengan menggunakan MinPts=5 dan Eps=1.



Gambar 12.1 Core dan Border

Menurut definisi, terdapat adanya 2 jenis fokus di dalam sebuah grup: Titik inti di dalam klaster dan titik

perbatasan di tepi klaster, di mana tetangga titik perbatasan memiliki item yang secara signifikan lebih sedikit daripada tetangga titik inti (Ester et al., 1996) . Titik garis mungkin memiliki tempat dengan lebih dari 1 grup.



Gambar 12.2 Konsep Kepadatan


3. Cluster DBSCAN

DBSCAN melacak sebuah cluster dengan memfilter ϵ ingkungan (Eps-neighborhood) untuk setiap titik dalam kumpulan data. Jika ϵ ketetanggaan titik p berisi lebih dari MinPts , kelompok lain dengan p sebagai pusat item dibuat. Setelah itu, DBSCAN mengumpulkan objek kerapatan secara iteratif. dapat dijangkau secara langsung dari objek inti yang mungkin memerlukan beberapa cluster-cluster yang density - reachable.

a. Directly density-reachable

Seandainya suatu jarak diantara keduanya kurang dari nilai Eps maka seharusnya titik benda mudah dijangkau dari titik yang lain. Ketebalan langsung dapat dijangkau = titik q dianggap ketebalan langsung dapat dicapai dari titik p , jika

dalam titik q adalah $\in \text{Neps}(p)$ dan p adalah titik pusat. $\text{NEps}(p): \{ q \text{ memiliki tempat dengan } D \mid \text{dist}(p,q) \leq \text{Eps} \}$ Pemisahan yang dimulai dari satu titik kemudian ke titik berikutnya tidak lebih dari nilai Eps .




Gambar 12. 1 Directly Density-Reachable

b. Reachable of Density

Density-reachable adalah suatu titik elemen yang dapat diakses jika terdapat rantai yang terhubung antara dua titik yang hanya berisi titik-titik dari titik elemen lain. Density-reachable yang dapat diakses langsung dari titik sebelumnya.


objek p adalah Ketebalan yang dapat dicapai dari item q mengenai ϵ dan MinPts dalam sekumpulan artikel D jika terdapat pengelompokan item $p_1, p_2, \dots, p_n$, dimana $p_1 = q$ dan $p_n = p$, dimana p_i Ketebalan $+1$ dapat dicapai langsung dari p_i dengan respek ke ϵ dan MinPts , untuk $1 \leq i \leq n$, p_i anggota D .



Gambar 12. 2 Density-reachable

c. Density-connected

Sebuah objek p adalah ketebalan yang terkait dengan objek q seperti untuk Eps dan MinPts dalam kumpulan objek D, Eps dan MinPts dapat dicapai ketebalan o jika ada item o komponen D sedemikian rupa dari p dan q.



Gambar 12. 3 Connected of Density

d. Cluster

Asumsikan D adalah database titik. Grup teks C. Eps dan MinPts adalah himpunan yang tak kosong D yang memenuhi syarat berikut:

$\forall p, q$: jika $p \in C$ dan q adalah ketebalan yang dapat dicapai dari p wrt. Eps dan $MinPts$, lalu $q \in C$. (Maksimal).

$\forall p, q \in C$: p dan q wrt dihubungkan dengan kerapatan. Konektivitas $MinPts$ dan EPS).

e. Algoritma DBSCAN

Cara masuk ke perhitungan DBSCAN adalah untuk masing-masing simpul dalam sebuah cluster, sebuah ketetanggaan dengan radius tertentu harus memiliki jumlah titik minimum, atau kepadatan tetangganya harus lebih besar dari ambang tertentu. Agar algoritma ini dapat melakukan clustering, diperlukan dua parameter masukan yaitu:

Eps , kemiringan menentukan batas ketetanggaan titik ($Eps - neighborhood$);

$MinPts$, skor minimal harus berada di sekitar Eps . Biasanya ada enam langkah dalam urutan algoritma DBSCAN, jadi :

- Pilih titik awal secara acak. • Dapatkan semua titik kepadatan yang dapat diakses di titik p .
- Cluster terbentuk jika p adalah titik pusat
- DBSCAN akan mengakses titik berikutnya dalam database seandainya p adalah sebuah titik tepi, dan juga tidak ada hubungan yang dapat diakses kepadatan p .

- Pemrosesan dapat dilanjutkan ke tahap selanjutnya setelah semua poin dapat diproses.
- Urutan poin yang dilakukan tidak berpengaruh terhadap hasil.

f. Evaluasi Clustering

Evaluasi clustering dapat digunakan untuk menentukan derajat clustering dari suatu data. Didalam penelitian ini evaluasi cluster yang digunakan adalah, koefisien bayangan dan indeks Davies-Bouldin (DBI). Setelah mendapatkan data dari proses clustering, akan didapatkan banyak kelas.

4. Metode Evaluasi Clustering

a. Silhouette Coefficient

Teknik ini merupakan strategi penilaian kelompok memadukan antara metode Cohesive dan metode split. Cohesive diperkirakan dengan memasukkan setiap item dalam kelompok, dan keterpisahan diperkirakan dengan menghitung pemisahan normal dari setiap artikel dalam kelompok ke kelompok terdekat (Rendon, 2011) (Prameshti, et al. (Wira et al. , 2017) 2019). Jarak antar informasi ditentukan dengan menggunakan resep jarak Euclidean. Untuk memberikan data tentang sifat pengelompokan yang menghasilkan sistem pengelompokan, bayangan masing-masing kelompok

dan, secara mengejutkan, keseluruhan kelompok dapat ditentukan dari kerja perhitungan pengelompokan. Garis besar insentif untuk dataset dengan k tandan dapat dicirikan sebagai $sil(k)$ yang ditentukan oleh kondisi (3), khususnya garis besar normal insentif untuk semua kelompok.

$$sil(c) = sil(k) \frac{1}{|k|} \sum_{i=1}^k sil(c_i)$$

Dimana:

$sil(k)$: nilai, silhouette semua cluster $|k|$: banyaknya cluster k $sil(c_i)$: rata-rata nilai silhouette.

b. Davies Bouldin Index (DBI)

Strategi penilaian interior memperkirakan penilaian kelompok dalam teknik pengumpulan, penyatuan dicirikan sebagai jumlah kedekatan informasi dengan pusat kelompok yang diikuti. Sedangkan jarak antar centeroid cluster menjadi dasar pemisahan.

Sun of Square inside group (SSW) adalah syarat yang digunakan untuk menentukan kisi-kisi gabungan dalam suatu kelompok - I yang dibentuk sebagai berikut:

Dari keadaan ini, m_i adalah jumlah informasi pada cluster ke-i, c_i adalah centeroid Kumpulan ke-i dan $d()$ adalah jarak setiap informasi ke centeroid yang ditentukan dengan menggunakan jarak Euclidean..

$$ssw_i = \frac{1}{m_i} \sum_{j=i}^{m_i} d(x_j, c_i)$$

Jumlah kuadrat antar tandan (SSB) adalah syarat yang digunakan untuk menentukan pembagian antar kelompok yang ditentukan dengan menggunakan syarat:

$$ssb_{ij} = d(c_i, c_j)$$

Pengukuran rasio ($\frac{SSW_i}{SSB_{ij}}$) dilakukan untuk memastikan nilai perbandingan antara cluster ke-i dan cluster ke-j setelah terkumpulnya nilai kohesi dan separasi. Grup yang baik adalah grup yang memiliki nilai persatuan terkecil dan partisi terbaik. Persamaan berikut digunakan untuk menentukan nilai rasio:

Nilai proporsi yang didapat digunakan untuk mencari nilai davies-bouldin record (DBI) dari kondisi berikut:

$$R_{ij} = \frac{SSW_i + SSW_j}{SSB_{ij}}$$

Dari situasi ini, k adalah jumlah grup yang digunakan. Semakin rendah penghargaan DBI (non-negatif ≥ 0), maka akan semakin baik sebuah cluster yang diperoleh dengan k-means cluster

$$DBI = \frac{1}{K} \sum_{i=1}^k \max_{i \neq j} (R_{ij})$$

C. Latihan

- a. Sebutkan dan jelaskan tahapan perencanaan evaluasi clustering!
- b. Sebutkan dan jelaskan Cluster – cluster DBSCAN!
- c. Sebutkan dan jelaskan metode evaluasi clustering!
- d. Sebutkan empat penerapan algoritma DBSCAN dalam berbagai sektor!

D. Referensi

- Gede, A., Pradnyana, S., Kom, M., Kom, K., Agustini, S., & Si, M. (n.d.). *Konsep Dasar Data Mining*.
- Han, J., Kamber, M., & Pei, J. (2011). *Data Mining. Concepts and Techniques, 3rd Edition (The Morgan Kaufmann Series in Data Management Systems)*.
- Jawad, M., & Mughal, H. (2018). *Data Mining: Web Data Mining Techniques, Tools and Algorithms: An Overview*. Retrieved from www.ijacsa.thesai.org
- Maimon, O., & Rokach, L. (n.d.). *Data Mining and Knowledge Discovery Handbook (Second Edition)*.
- Rinna Rachmatika, A. (2020). Perbandingan Model Klasifikasi untuk Evaluasi Kinerja Akademik Mahasiswa. *Jurnal Edukasi dan Penelitian Informatika*, 1-6.
- Suntoro, J., & Kom, M. (n.d.). *DATA MINING Algoritme dan Implementasi Menggunakan Bahasa Pemrograman PHP*.